

《信息、控制与计算》

立


Chapter 1 熵和互信息

- 事件

	表达式	性质
自信息	$I(x) = -\log p(x)$	/
条件自信息	$I(x y) = -\log p(x y) = I(x, y) - I(y)$	差集
联合自信息	$I(x, y) = -\log p(x, y)$	并集
互信息	$I(x; y) = \log \frac{p(x y)}{p(x)} = \log \frac{p(x, y)}{p(x)p(y)} = I(x) - I(x y) = I(x) + I(y) - I(x, y)$	交集，有对称性
条件互信息	$I(x; y z) = \log \frac{p(x, y z)}{p(x z)p(y z)} = I(x z) + I(y z) - I(x, y z)$	差集的交集
联合互信息	$I(x; y, z) = \log \frac{p(x y, z)}{p(x)} = I(x; y) + I(x; z y) = I(y; x) + I(z; x y) = I(y, z; x)$	并集的交集

- 离散随机变量

熵是随机变量的平均自信息，代表了平均不确定值



	表达式	性质
平均自信息 (熵)	$H(X) = E[I(x)] = \sum_k p(x_k) I(x_k) = - \sum_k p(x_k) \log p(x_k)$	/
条件熵	$H(X Y) = E[I(X y)] = \sum_y p(Y=y) H(X Y=y) = - \sum_x \sum_y p(x,y) \log p(x y)$	差集
联合熵	$H(X,Y) = - \sum_x \sum_y p(x,y) \log p(x,y) = H(X Y) + H(Y) = H(Y X) + H(X)$ $= H(X) + H(Y) - I(X;Y)$	并集
平均互信息	$I(X;Y) = E[I(x;y)] = \sum_x \sum_y p(x,y) \log \frac{p(x,y)}{p(x)p(y)} = \sum_x \sum_y p(x,y) \log \frac{p(x,y)}{p(x)p(y)}$ $= H(X) - H(X Y) = H(Y) - H(Y X)$	交集， 有对称性
条件互信息	$I(X;Y Z) = E[I(x;y z)] = \sum_x \sum_y \sum_z p(x,y,z) \log \frac{p(x,y,z)}{p(x z)p(y z)}$	差集的交集
联合互信息	$I(X;Y,Z) = E[I(x;y,z)] = \sum_x \sum_y \sum_z p(x,y,z) \log \frac{p(x,y,z)}{p(x)} = I(X;Z) + I(X;Y Z)$	并集的交集

◦ 概率分布的散度——相对熵

令 $\{p(x)\}$ 与 $\{q(x)\}$ 是同一字符表 \mathcal{X} 上的两个概率分布，相对熵表示的是实际分布 $\{p(x)\}$ 与假定分布 $\{q(x)\}$ 间的平均差距，又称“鉴别熵”。

$$D(p//q) = E_p \left\{ \log \frac{p(x)}{q(x)} \right\} = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

性质： (1) $D(p//q) \geq 0$ (2) $D(p//q) \neq D(q//p)$ (3)

$$I(X;Y) = \sum_x p(x,y) \log \frac{p(x,y)}{p(x)p(y)} = D(p(x,y)//p(x)p(y)) \geq 0$$

◦ 关于疑义度的 Fano 不等式

把 \hat{X} 看成是对 X 的估计，定义错误概率为 $P_E = \sum_{k=0}^{K-1} \sum_{\substack{j=0 \\ k \neq j}}^{K-1} P\{X=k, \hat{X}=j\}$

于是关于疑义度 $H(X|\hat{X})$ 有如下不等式： $H(X|\hat{X}) \leq H(P_E) + P_E \log(K-1)$

物理意义： 已知 \hat{X} 条件下， X 的不确定性。若 \hat{X} 正确，其不确定性为 $H(P_E)$ ；若 \hat{X} 不正确，此时 X 的取值范围为剩下 $K-1$ 个值，这部分不确定性不会大于 $P_E \log(K-1)$

• 连续随机变量

随机变量 X, Y 的概率密度为 $f_X(x), f_Y(y)$ ，联合概率密度为 $f_{XY}(x, y)$ 有

$$\begin{cases} f_X(x) = \int_{-\infty}^{\infty} f_{XY}(x, y) dy \\ f_Y(y) = \int_{-\infty}^{\infty} f_{XY}(x, y) dx \\ f_{XY}(x, y) = f_X(x) f_{Y|X}(y|x) = f_Y(y) f_{X|Y}(x|y) \end{cases}$$

	表达式	性质
互信息	$I(X; Y) = \iint f_{XY}(x, y) \log \frac{f_{XY}(x, y)}{f_X(x) f_Y(y)} dx dy = \iint f_{XY}(x, y) \log \frac{f_{XY}(x, y)}{f_X(x) f_Y(y)} dx dy$ $= H_c(X) - H_c(Y X) = H_c(Y) - H_c(X Y) = H_c(X) + H_c(Y) - H_c(X, Y)$	/
条件互信息	$I(X; Y Z) = \iiint f_{XYZ}(x, y, z) \log \frac{f_{XY Z}(x, y z)}{f_{X Z}(x z) f_{Y Z}(y z)} dx dy dz$	差集
联合互信息	$I(X; Y, Z) = \iiint f_{XYZ}(x, y, z) \log \frac{f_{XYZ}(x, y, z)}{f_{X,Y}(x, y) f_Z(z)} dx dy dz$ $= I(X; Y) + I(X; Z Y) = I(X; Z) + I(X; Y Z)$	并集
微分熵	$H_c(X) = - \int f_X(x) \log f_X(x) dx$	连续随机变量离散化，不具有线性变换不变性，表征 <u>相对不确定性</u> ， <u>可正可负</u> 。
条件微分熵	$H_c(X Y) = - \iint f_{XY}(x, y) \log f_{X Y}(x y) dx dy$	
联合微分熵	$H_c(X, Y) = - \iint f_{XY}(x, y) \log f_{XY}(x, y) dx dy = H_c(X) + H_c(Y X)$	

微分熵极大化

峰值受限：if $X \in [-M, M]$ then $H_c(X) \leq \ln(2M)$

平均功率受限：if $\sigma^2 = \text{const}$, $X \sim N(\mu, \sigma^2)$ then $H_c(X) \leq \ln(\sqrt{2\pi e} \sigma) = \frac{1}{2} \ln(2\pi e \sigma^2)$

熵功率： $\bar{\sigma}_x^2 = \frac{1}{2\pi e} e^{2H_c(x)} \leq \sigma_x^2$

$$e^{2H_c(X+Y)} \leq e^{2H_c(X)} + e^{2H_c(Y)}$$

平稳信源的熵及其性质

设信源发出序列为 N 维随机矢量 $\mathbf{X} = (X_1, X_2, \dots, X_N)$ ，则信源熵表示为：

$$H(\mathbf{X}) = - \sum p(x_{i_1}, x_{i_2}, \dots, x_{i_N}) \log p(x_{i_1}, x_{i_2}, \dots, x_{i_N})$$

平均每符号熵: $H_N(\mathbf{X}) \triangleq \frac{1}{N}H(\mathbf{X}) = \frac{1}{N}H(X_1, X_2, \dots, X_N)$

熵速率: $H_\infty(\mathbf{X}) = \lim_{N \rightarrow \infty} H_N(\mathbf{X})$ 即最小平均符号熵。

平均条件熵: $H(X_N | X_{N-1}, X_{N-2}, \dots, X_1)$

熵的相对率: $\eta = \frac{H_\infty}{H_0} = \frac{H_\infty}{\log K}$

信源冗余度: $R = 1 - \eta$

性质:

- (1) 平均每符号熵、平均条件熵随 N 增大单调不减。
- (2) $H_N(\mathbf{X}) \geq H(X_N | X_{N-1}, X_{N-2}, \dots, X_1)$
- (3) $\lim_{N \rightarrow \infty} H_N(\mathbf{X}) = \lim_{N \rightarrow \infty} H(X_N | X_{N-1}, X_{N-2}, \dots, X_1)$
- (4) 对于无记忆离散源, 当 X 在取值范围内等概率分布时熵最大, 且有 $H_\infty \leq \dots \leq H_1 \leq H_0 = \log K$

Chapter 2 离散无记忆信源的无损编码

- 离散无记忆信道的等长编码

- 等长编码

设信源输出长度为 L 的消息序列, 字符表含 K 个字符, 则共有 K^L 种不同序列。用长度为 N , 包含 D 个字符的编码字符序列来进行无差错等长编码, 则要求 $D^N \geq K^L$, 即 $N \geq \frac{L \log K}{\log D}$ 。(所有可能的编码序列数比消息序列数大)

(1) **平均码长**: $\bar{N} = \frac{N}{L} \geq \log_K K \stackrel{\text{十进制}}{K=10} 3.322 \text{ bit}$

(2) 当等概率输出序列字符时, 信源熵最大, 为 $\log K$

(3) **编码速率**: $R = \frac{N}{L} \log D \geq \log K$

- 等长编码定理

令离散无记忆信源熵为 $H(U)$, 若 $N > L[H(U) + \varepsilon_L] / \log D$, 则可实现无损编码。

- 渐近等分性质 AEP

对于 DMS (离散无记忆信源) 而言, $\lim_{L \rightarrow \infty} I_L = \lim_{L \rightarrow \infty} \frac{I(u^L)}{L} \xrightarrow{P=1} H(U)$ 表示平均每符号自信息以概率 1 趋于熵

其中, u^L, L 分别为输出序列及其长度, $I(u^L) = \sum I(u_i)$ 表示序列自信息等于每个字符的自信息之和 (由于无记忆性)

- 典型列

$A_\varepsilon^{(L)}(U) = \{u^L; H(U) - \varepsilon \leq I_L \leq H(U) + \varepsilon\}, \varepsilon > 0$

性质:

(1) L 足够大时, $P(u^L \in A_\varepsilon^{(L)}(U)) > 1 - \varepsilon$

(2) 若 $u^L \in A_\varepsilon^{(L)}(U)$, 则有 $2^{-L[H(U)+\varepsilon]} \leq p(u^L) \leq 2^{-L[H(U)-\varepsilon]}$, 即每个序列出现概率 $p(u^L) \approx 2^{-LH(U)}$

(3) 典型列数目 $|A_\varepsilon^{(L)}(U)|$ 满足 $(1 - \varepsilon)2^{L[H(U)-\varepsilon]} \leq |A_\varepsilon^{(L)}(U)| \leq 2^{L[H(U)+\varepsilon]}$, 即 $|A_\varepsilon^{(L)}(U)| \approx 2^{LH(U)}$

- 离散无记忆信道的不等长编码

码唯一可译: 后缀分解集中不含码字

码唯一可译且即时: 第一个后缀分解集为空集, 即 $S_1 = \emptyset$

- Kraft 不等式

存在长度为 n_1, n_2, \dots, n_k 的 D 元异字头码的充要条件为: $\sum_{k=1}^K D^{-n_k} \leq 1$

一个码唯一可译 \iff Kraft 不等式成立 \iff 存在一个具有同样长度的异字头码

不等长编码定理

平均码长: $\bar{n} = \sum p_k \cdot n_k$

任何一个唯一可译码的平均码字长度必须满足: $\bar{n} \geq \frac{H(U)}{\log D}$

同时一定存在一个 D 元唯一可译码, 其平均码长满足: $\bar{n} \leq \frac{H(U)}{\log D} + 1$

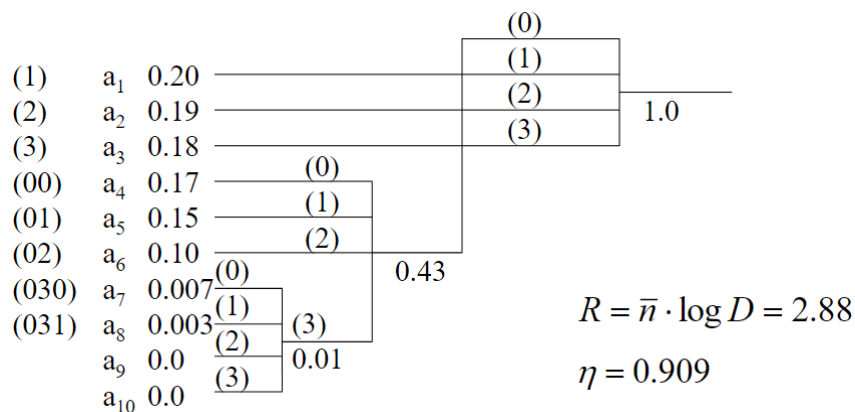
编码速率: $R = \bar{n} \log D$

编码效率: $\eta = \frac{H(U)}{R} = \frac{-\sum p_k \log p_k}{R}$

最佳不等长编码——Huffman 编码

对 K 个信源, 进行 D 元 Huffman 编码时, 每次合并 D 个概率最小的消息, 满足 $K = (D-1) \cdot i + 1$ 。

若 $K = (D-1) \cdot i + M$ $M = 2, 3, \dots, D-1$, 则需添补 $D-M$ 个概率为零的虚拟消息, 再合并。



Shannon 编码

对于每个信息, 其概率为 p_k , 码长为 l_k 。令 $P_k = \sum_{i=1}^{k-1} p_i$

用 $l_k = \lceil \log \frac{1}{p_k} \rceil$ 个比特来表示 P_k , 将 P_k 以二进制的形式表示, 取小数前 l_k 位, 即为对应编码。是前缀码。


p_k	0.4	0.25	0.2	0.15
l_k	2	2	3	3
P_k	0	0.4	0.65	0.85
二进制	0.00000	0.01100	0.10100	0.11011
码字	00	01	101	110

Fano 编码

将消息按概率降序排列并分成两大组, 使这两组的概率差尽可能小, 左边赋 0 右边赋 1;

重复上述步骤直至每组只有一个信息。

$$U = \begin{pmatrix} a_1 & a_2 & a_3 & a_4 & a_5 & a_6 \\ 0.3 & 0.25 & 0.2 & 0.15 & 0.05 & 0.05 \end{pmatrix}$$



编码效率:
 $\eta = 0.99$

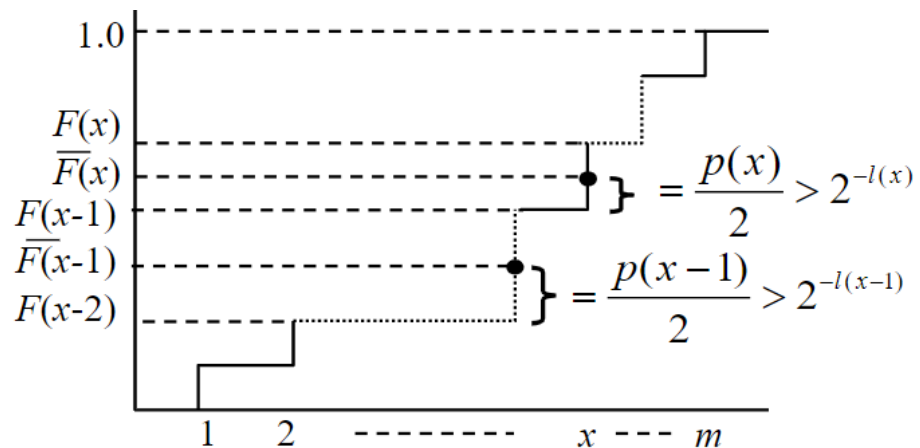
$$\bar{n} \leq H(U) + 1 - 2p_n$$

其中 p_n 为最小符号概率。

◦ S.FE编码

令 $U = \begin{bmatrix} a_1 & a_2 & \cdots & a_m \\ p(1) & p(2) & \cdots & p(m) \end{bmatrix}$, 记 $\bar{F}(x) \stackrel{\text{def}}{=} \sum_{i < x} p(i) + \frac{1}{2}p(x)$ $F(x) \stackrel{\text{def}}{=} \sum_{i \leq x} p(i)$

(事实上 $\bar{F}(x) = F(x) - \frac{1}{2}p(x) = F(x-1) + \frac{1}{2}p(x)$, 即 $\bar{F}(x) = \frac{1}{2}[F(x) + F(x-1)]$)



将 $\bar{F}(x)$ 按二进制形式表示, 取小数前 $l(x)$ 位, 即对应编码。其中 $l(x) = \lceil \log \frac{1}{p(x)} \rceil + 1$

。


平均码长 $\bar{n} = \sum p(x)l(x)$

x	$p(x)$	$F(x)$	$\bar{F}(x)$	$\bar{F}(x)$ 的二进表示	$l(x)$	码字	Huffman 码
1	0.25	0.25	0.125	0.001	3	001	01
2	0.5	0.75	0.5	0.10	2	10	1
3	0.125	0.875	0.8125	0.1101	4	1101	001
4	0.125	1.0	0.9375	0.1111	4	1111	000

◦ 马尔可夫信源编码

$$\frac{H_\infty(U)}{\log D} \leq \bar{n} < \frac{H_\infty(U)}{\log D} + \frac{1}{L} \quad H_\infty(U) = \sum q(S=s)H(U|S=s) = H(U|S)$$

$q(S=s)$ 表示平稳分布时的概率, $H(U|S=s) = -\sum p(s) \log p(s)$, $p(s)$ 为进入下一步的概率。



$$\begin{aligned}
 q(A) &= q(D) = 5/12, \quad q(B) = q(C) = 1/12 & \therefore H(X|S) &= \sum_{s \in \{A, B, C, D\}} q(s) H(X|s) = 0.558 \\
 H(X|S=A) &= H(X|S=D) = 0.469 & \therefore \text{二元编码时} & \\
 H(X|S=C) &= H(X|S=B) = 1 & \bar{n}_{opt} &= H_{\infty} / \log 2 = H(X|S) = 0.558
 \end{aligned}$$

Chapter 3 信道、信道容量以及信道编码定理

- 离散无记忆信道

若离散信道对于任何 n ，都有 $p(y^n|x^n) = \prod_{i=1}^n p(y_i|x_i)$ ，则称该信道为 **离散无记忆信道 (DMC)**。

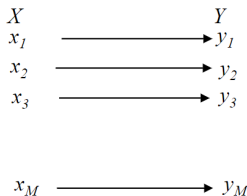
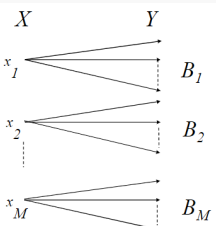
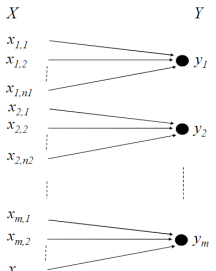
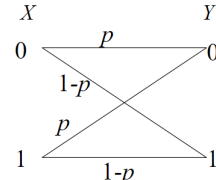
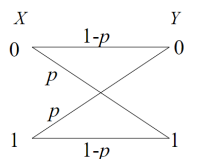
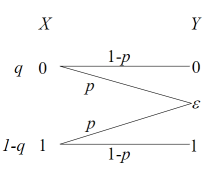
若对任何 i 和 l 有 $p(y_i = j|x_i = k) = p(y_l = j|x_l = k)$ ，则称该信道是 **平稳/恒参** 的。

- 信道容量

信道容量指，对于给定的信道而言能传输的最多的信息量，即互信息能够达到的最大值。

$$C = \lim_{n \rightarrow \infty} \frac{1}{n} \max I(X_1 X_2 \dots X_n; Y_1 Y_2 \dots Y_n) = \max I(X; Y) = \max[H(Y) - H(Y|X) \text{ or } H(X) - H(X|Y)]$$

$$I(X_1 X_2 \dots X_n; Y_1 Y_2 \dots Y_n) \leq \sum_{i=1}^n I(X_i; Y_i) = nI(X; Y) \quad \text{当输入为独立随机序列时取等号。}$$

信道	信道容量	信道示意图
无噪信道	$C = \log M(\text{bit})$	 $ \begin{aligned} H(X Y) &= 0 \\ I(X;Y) &= H(X) \\ C &= \max_{\{Q_X\}} I(X;Y) \\ &= \max_{\{Q_X\}} H(X) \\ &= \log M \quad \text{比特} \end{aligned} $
无损信道	$C = \log M(\text{bit})$	 $ \begin{aligned} H(X Y) &= 0 \\ I(X;Y) &= H(X) \\ C &= \max_{\{Q_X\}} I(X;Y) \\ &= \max_{\{Q_X\}} H(X) \\ &= \log M \quad \text{比特} \end{aligned} $
确定信道	$C = \log m(\text{bit})$	 $ \begin{aligned} p(y_j x_i) &= 0 \text{ 或 } 1 \\ I(X;Y) &= H(Y) - H(Y X) \\ &= H(Y) \\ C &= \max_{\{Q_X\}} I(X;Y) \\ &= \max_{\{Q_X\}} H(Y) \\ &= \log m \quad \text{比特} \end{aligned} $
无用信道	$C = 0$	 $ \begin{aligned} p(y_j x_i) &= p(y_j) \\ p(x_i y_j) &= p(x_i) \\ H(X Y) &= H(X) \\ I(X;Y) &= 0 \\ C &\equiv 0 \end{aligned} $
二进制对称信道	$C = 1 - H(p)$ (输入等概时成立)	 $ \begin{aligned} I(X;Y) &= H(Y) - H(Y X) \\ &= H(Y) - \sum_x p(x) H(Y X=x) \\ &= H(Y) - \sum_x p(x) H(p) \\ &= H(Y) - H(p) \\ &\leq 1 - H(p) \end{aligned} $ <p>当输入取等概分布时，输出Y也为等概分布，所以等号可以成立，即 $C=1-H(p)$。</p>
二进制删除信道	$C = 1 - p$	 $ \begin{aligned} C &= \max_{\{Q_X\}} I(X;Y) \\ &= \max_{\{Q_X\}} \{H(Y) - H(Y X)\} \\ &= \max_{\{Q_X\}} H(Y) - H(p) \\ H(Y) &= H(q(1-p), p, (1-q)(1-p)) \\ &= H(p) + (1-p)H(q) \\ C &= \max_{\{Q_X\}} H(Y) - H(p) \\ &= \max_q (1-p)H(q) \\ &= (1-p) \end{aligned} $ <p>当输入为等概分布时，等号成立。</p>

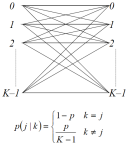
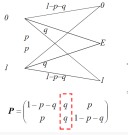
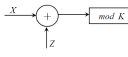
• 对称离散无记忆信道容量

若信道转移概率矩阵 $\mathbf{P} \in \mathbb{R}^{K \times J}$ 的每行都是第一行的一个置换，则输入对称；每列是第一列的一个置换，则输出对称。

若信道输入输出均对称，则称其为对称信道， $C = \log J + \sum_{j=0}^{J-1} p(j|k) \log p(j|k)$ ；若仅仅输入对称，则上式 = 改为 \leq

若把信道输出字符集合划分成若干子集，这些子集对应 \mathbf{P} 中列组成的子阵满足每行是第一行的置换，每列是第一列的置换，则这个信道是准对称信道。

准对称信道容量定理：达到准对称信道容量的输入概率分布为等概分布。

信道	信道容量	信道示意图
K 元对称信道	$C = \log K - H(p) - p \log(K-1)$	 $C = \log K + \sum_{j=1}^{K-1} p(j k) \log p(j k)$ $= \log K + (1-p) \log(1-p) + p \log \frac{p}{K-1}$ $= \log K - H(p) - p \log(K-1)$ $p(j k) = \begin{cases} 1-p & k=j \\ \frac{p}{K-1} & k \neq j \end{cases}$
二进制删除信道	$C = (1-p-q) \log(1-p-q) + p \log p + (1-q) \log \frac{1-q}{2}$	 $Q_0 = Q_1 = 0.5$ $C = H(X=0; Y) = H(X=k; Y)$ $= (1-p-q) \log \frac{1-p-q}{(1-q)^2} + q \log \frac{q}{(1-q)^2} + p \log \frac{p}{(1-q)^2}$ $= (1-p-q) \log(1-p-q) + p \log p + (1-q) \log \frac{(1-q)}{2}$ $p = \begin{pmatrix} 1-p-q & q \\ p & 1-p-q \end{pmatrix}$
模 K 加法信道	$C = \log K - H(z)$	 $Y = X + Z \bmod K$ $X, Y, Z \in \{0, 1, 2, \dots, K-1\}$ $p(z) \text{ 为任意分布}$

信道的组合

积信道（平行组合信道）

当输入独立且各自达到分量信道容量时，积信道就可达到其信道容量 $C = \sum C_i$

和信道（开关信道）

信道被选中的概率之和为 1

$2^C = 2^{C_1} + 2^{C_2} + \dots$ ，即 $C = \log(\sum 2^{C_i})$ ，这时每个信道的利用概率为

$$P_n = 2^{C_i} / 2^C = 2^{C_i - C} \quad i = 1, 2, \dots, N$$


级联信道

前一个信道的输出作为后一个信道的输入

$C \leq \min\{C_1, C_2, \dots, C_n\}$ ，且级联信道容量趋于零。

加性高斯噪声信道

时间离散，输入输出连续。输入 X 为高斯分布时等号成立。



容量：


$$\therefore I(X; Y) = h(Y) - h(Y|X) = h(Y) - h(X + Z|X) = h(Y) - h(Z) \leq \frac{1}{2} \log(1 + \frac{P}{N}) \quad \therefore C = \frac{1}{2} \log(1 + \frac{P}{N})$$

平行高斯信道

$$C = \frac{1}{2} \sum_{i=1}^k \log(1 + \frac{P_i}{N_i})$$

注水法则：先把功率分配给噪声小的信道，就像灌水一样进行，直到总的灌水量为总功率 P 。
(必考！)

附：级联时按噪声比例分配



- 信源信道分离编码

若信源、信道编码速率满足 $H < R_s < R_c < C$ ，则可以通过信源和信道分别编码使总误码率 P_e 趋于零。

- 信源信道联合编码

若随机序列熵速率 $H_\infty(U) < C$ ，则存在一个信源—信道联合编码，使 $P_e^{(n)} \rightarrow 0$

Chapter 4 率失真信源编码

最小平均失真度： $D_{\max} = \min_{\hat{x} \in \hat{X}} \sum_x p(x) d(x, \hat{x})$ (分布概率向量与失真矩阵相乘得到的新向量取最小值)

最大失真度： $D_{\min} = \sum_x p(x) \min_{\hat{x} \in \hat{X}} d(x, \hat{x})$ (找失真矩阵第 i 行的最小值与 p_i 相乘并求和)

平均失真度： $D = \sum p(x) q(\hat{x}|x) d(x, \hat{x})$

率失真函数： $R(D) = \min_{E d(X, \hat{X}) \leq D} I(X; \hat{X}) = H(\hat{X}) - H(\hat{X}|X)$

例：设二元等概信源 $\begin{pmatrix} X \\ p(x) \end{pmatrix} = \begin{pmatrix} x_0 & x_1 \\ 0.5 & 0.5 \end{pmatrix}$ ，再生字符表为 $\hat{X} = \{\hat{x}_0, \hat{x}_1, \hat{x}_2\}$ ，失真度矩阵为 $(d)_{2 \times 3} = \begin{pmatrix} 0 & \infty & 1 \\ \infty & 0 & 1 \end{pmatrix}$ ，求 $R(D)$

解：

(1) $D_{\max} = 1$ 、 $D_{\min} = 0$

(2) 存在与失真度量矩阵具有同样对称性的概率转移分布矩阵 $Q = \begin{pmatrix} \alpha & \beta & \gamma \\ \beta & \alpha & \gamma \end{pmatrix}$ ， $\alpha + \beta + \gamma = 1$

(3) 由于 $d(x_0, \hat{x}_1) = d(x_1, \hat{x}_0) = \infty$ ，因此 $\beta = 0$ ，即 $Q = \begin{pmatrix} \alpha & 0 & 1 - \alpha \\ 0 & \alpha & 1 - \alpha \end{pmatrix}$

(4) 求得 $D = \sum p(x) q(\hat{x}|x) d(x, \hat{x}) = \frac{1}{2}[\alpha * 0 + (1 - \alpha) * 1] + \frac{1}{2}[\alpha * 0 + (1 - \alpha) * 1] = 1 - \alpha$ ，所以 $\alpha = 1 - D$

(5) 求得 $R(D) = \min I(X; Y) = H(\frac{\alpha}{2}, \frac{\alpha}{2}, 1 - \alpha) - H(\alpha, 1 - \alpha) = \alpha = 1 - D$

Chapter 5 计算理论

- Kolmogorov复杂度

关于一个通用计算机 u ，二元字符串 x 的 Kolmogorov 复杂度定义为即能够输出并且停止的所有程序的最小长度。

$$K_u(x) = \min_{u(p)=x} l(p) \leq K_u(x|l(x)) + 2 \log l(x) + c$$

- 机器学习方法分类

监督学习：从标记的训练数据来推断一个功能的机器学习任务。如分类、回归等。

非监督学习：在未标记的数据中，试图找到隐藏的结构。如聚类、密度估计。

强化学习：强调如何基于环境而行动，以取得最大化的预期利益。

- 贝叶斯学习

极大后验 (MAP) 策略规则：给定数据 D ，在候选假设集合 H 中寻找可能性最大的假设 h 。

$$h_{MAP} = \arg \max_{h \in H} P(h|D) = \arg \max_{h \in H} P(D|h)P(h)$$

极大似然 (ML) 策略规则：假设集合 H 的每个假设有相同的先验概率 $P(h_i) = P(h_j)$

$$h_{ML} = \arg \max_{h \in H} P(D|h)$$

- 朴素贝叶斯分类

给定实例的属性 $\langle a_1, a_2, \dots, a_n \rangle$ ，取最可能的目标值 v_{MAP}

$$v_{MAP} = \arg \max_{v_j \in V} P(v_j|a_1, a_2, \dots, a_n) = \arg \max_{v_j \in V} P(a_1, a_2, \dots, a_n|v_j)P(v_j) = \arg \max_{v_j \in V} \prod_i P(a_i|v_j)$$

$$v_{NB} = \arg \max_{v_j \in V} P(v_j) \prod_i P(a_i|v_j)$$

$$\begin{aligned} v_{NB} &= \arg \max_{v_j \in V} P(v_j) \\ &\quad * P(\text{Outlook} = \text{Sunny}|v_j)P(\text{Temperature} = \text{Cool}|v_j) \\ &\quad * P(\text{Humidity} = \text{High}|v_j)P(\text{Wind} = \text{Strong}|v_j) \end{aligned}$$

计算结果：

$$P(\text{PlayTennis} = \text{Yes}) = 9/14 = 0.64;$$

$$P(\text{PlayTennis} = \text{No}) = 5/14 = 0.36$$

$$P(\text{Wind} = \text{Strong}|\text{PlayTennis} = \text{Yes}) = 3/9 = 0.33$$

$$P(\text{Wind} = \text{Strong}|\text{PlayTennis} = \text{No}) = 3/5 = 0.60$$

$$P(\text{Yes})P(\text{Sunny}|\text{Yes})P(\text{Cool}|\text{Yes})P(\text{High}|\text{Yes})P(\text{Strong}|\text{Yes}) = 0.0053$$

$$P(\text{No})P(\text{Sunny}|\text{No})P(\text{Cool}|\text{No})P(\text{High}|\text{No})P(\text{Strong}|\text{No}) = 0.02$$

- 决策树学习

- 信息增益

用熵来定义样例集合 S 的纯度：即 $Entropy(S) = -p_+ \log p_+ - p_- \log p_-$ 。其中 p_+ 为 S 中正例的比例， p_- 同理。

用信息增益度量期望熵降低：使用属性 A 相对于样例集合 S 的信息增益 $Gain(S, A)$ 定义为：

$$Gain(S, A) = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$

其中 $Values(A)$ 表示属性 A 中所有可能值的集合， S_v 是 S 中属性 A 的值为 v 的子集。

■ $\text{Values}(\text{Wind}) = \text{Weak}, \text{Strong}$

■ $S = [9+, 5-]$

■ $S_{\text{Weak}} = [6+, 2-]$

■ $S_{\text{Strong}} = [3+, 3-]$

$$\text{Gain}(S, \text{Wind}) = \text{Entropy}(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} \text{Entropy}(S_v)$$

$$= \text{Entropy}(S) - \left(\frac{8}{14}\right) \text{Entropy}(S_{\text{Weak}}) - \left(\frac{6}{14}\right) \text{Entropy}(S_{\text{Strong}})$$


$$= 0.94 - \frac{8}{14} * 0.811 - \frac{6}{14} * 1 = 0.048$$

◦ 感知器

例：两层的感知器网络实现异或布尔函数

第一层： $A \wedge B'$ 与 $B \wedge A'$

第二层： $A \oplus B = (A \wedge B') \vee (B \wedge A')$



Chapter 6 控制理论

• 传递函数

状态向量： $\vec{x} = [x_1, x_2, \dots, x_n]^T$

输入信号向量： $\vec{u} = [u_1, u_2, \dots, u_n]^T$

状态微分方程： $\dot{\vec{x}} = \mathbf{A}\vec{x} + \mathbf{B}\vec{u}$

系统输出方程： $\vec{y} = \mathbf{C}\vec{x} + \mathbf{D}\vec{u}$

(1) 拉普拉斯变换：

$\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u}$ $\mathbf{y} = \mathbf{C}\mathbf{x} + \mathbf{D}\mathbf{u}$	拉普拉斯变换 \longrightarrow	$s\mathbf{X}(s) = \mathbf{A}\mathbf{X}(s) + \mathbf{B}\mathbf{U}(s)$ $\mathbf{Y}(s) = \mathbf{C}\mathbf{X}(s) + \mathbf{D}\mathbf{U}(s)$
--	-----------------------------	---

(2) 引入 $\phi(s) = [s\mathbf{I} - \mathbf{A}]^{-1}$ ，则 $\mathbf{X}(s) = \phi(s)\mathbf{B}\mathbf{U}(s)$

(3) 从而 $\mathbf{Y}(s) = (\mathbf{C}\phi(s)\mathbf{B} + \mathbf{D})\mathbf{U}(s)$ $G(s) = \frac{\mathbf{Y}(s)}{\mathbf{U}(s)} = \mathbf{C}\phi(s)\mathbf{B} + \mathbf{D}$

• 可控性

充要条件：可控性矩阵 $U_c = [\mathbf{B}, \mathbf{A}\mathbf{B}, \dots, \mathbf{A}^{n-1}\mathbf{B}]$ 的秩为 n

• 可观性

充要条件：可观性矩阵 $U_0 = \begin{bmatrix} C \\ CA \\ \vdots \\ CA^{n-1} \end{bmatrix}$ 的秩为 n

• 稳定性

控制系统本身处于平衡状态。受到扰动，产生偏差。扰动消失后，偏差逐渐变小，能恢复到原来的平衡状态，则稳定。偏差逐渐变大，不能恢复到原来的平衡状态，则不稳定。即系统在初始偏差作用下，过渡过程的收敛性。

充要条件：传递函数所有极点位于左半平面。

◦ 劳斯判据

不求解特征方程的根，直接根据特征方程的系数，判断系统的稳定性，回避了解高次方程根的困难。

必要条件：特征方程所有系数大于零。只要有一项小于等于零，则不稳定。

充要条件：劳斯表中第一列元素全部大于0。若出现小于0的元素，则系统不稳定。且第一列元素符号改变的

次数等于系统正实部根的个数。

劳斯表：

s^n	a_n	a_{n-2}	a_{n-4}	a_{n-6}	\dots
s^{n-1}	a_{n-1}	a_{n-3}	a_{n-5}	a_{n-7}	\dots
s^{n-2}	A_1	A_2	A_3	A_4	\dots
s^{n-3}	B_1	B_2	B_3	B_4	\dots
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
s^2	D_1	D_2			
s^1	E_1				
s^0	F_1				

$A_1 = \frac{a_{n-1}a_{n-2} - a_n a_{n-3}}{a_{n-1}}, A_2 = \frac{a_{n-1}a_{n-4} - a_n a_{n-5}}{a_{n-1}}, A_3 = \frac{a_{n-1}a_{n-6} - a_n a_{n-7}}{a_{n-1}} \dots \text{全零}$
 $B_1 = \frac{A_1 a_{n-3} - a_{n-1} A_2}{A_1}, B_2 = \frac{A_1 a_{n-5} - a_{n-1} A_3}{A_1}, B_3 = \frac{A_1 a_{n-7} - a_{n-1} A_4}{A_1} \dots \text{全零}$

例：已知系统函数 $\phi(s) = \frac{1}{s^3 + 3s^2 + 2s + K}$ ，求使系统稳定时的 K 的取值范围。

解：

(1) 特征方程 $D(s) = s^3 + 3s^2 + 2s + K$ 。 $a_3 = 1, a_2 = 3, a_1 = 2, a_0 = K$

(2) 画出劳斯表如下：

s^3	1	2
s^2	3	K
s^1	$\frac{3 \times 2 - 1 \times K}{3}$	0
s^0	$\frac{6K - K^2}{6 - K}$	0

(3) 有 $\begin{cases} \frac{6-K}{3} > 0 \\ K > 0 \end{cases}$ 得到 $0 < K < 6$

◦ 李雅普诺夫方法

■ 间接法

A 的所有特征值 $\lambda \leq 0$ ，且为零的特征值无重根。传递函数极点即为特征值。

■ 直接法

系统运动需要能量。在非零初始状态作用下的运动过程中，若能量随时间衰减以致最终消失，则系统迟早会达到平衡状态，即系统渐近稳定。反之，系统则不稳定。若能量在运动过程中不增不减，则称为李雅普诺夫意义下的稳定。

